

**Università degli studi di Modena e Reggio Emilia**

**Dipartimento di Ingegneria**

---

*Corso di Laurea Magistrale in Ingegneria Informatica*

# **Adversarial Machine Learning per il Rilevamento di Botnet**

**Relatore:**

**Prof. Michele Colajanni**

**Candidato:**

**Alessandro Aleotti**

**Correlatore:**

**Ing. Mirco Marchetti**

---

**Anno Accademico 2017/2018**

# Indice

<b>1</b>	<b>Introduzione</b>	<b>2</b>
1.1	Citazioni . . . . .	2
1.2	Oggetti float . . . . .	2
1.2.1	Figure . . . . .	2
1.2.2	Tabelle . . . . .	3
1.3	Compilazione . . . . .	3
<b>2</b>	<b>Stato dell'arte</b>	<b>4</b>
<b>3</b>	<b>Progetto</b>	<b>5</b>
3.1	Classificatore Random Forest . . . . .	5
3.1.1	Dataset . . . . .	6
3.1.2	Features . . . . .	6
3.1.3	Output . . . . .	7
3.2	Classificatore Neurale . . . . .	8
3.2.1	Input . . . . .	8
3.2.2	Architettura . . . . .	9
3.2.3	Output . . . . .	11
3.2.4	Realizzazione Adversarial Learning . . . . .	11
3.3	Autoencoder . . . . .	11
3.3.1	Dataset Autoencoder . . . . .	12
3.3.2	Architettura Autoencoder . . . . .	13
3.4	Generative Adversarial Network . . . . .	18
3.4.1	Output . . . . .	18

<b>4</b>	<b>Implementazione</b>	<b>19</b>
4.1	Classificatore Random Forest . . . . .	19
4.1.1	Input . . . . .	20
4.1.2	Composizione Interna . . . . .	20
4.1.3	Output . . . . .	20
4.2	Classificatore Neurale . . . . .	20
4.2.1	Input . . . . .	20
4.2.2	Composizione Interna . . . . .	20
4.2.3	Output . . . . .	20
4.3	Realizzazione Adversarial Learning . . . . .	20
4.3.1	Input . . . . .	20
4.3.2	Composizione Interna . . . . .	20
4.3.3	Output . . . . .	20
<b>5</b>	<b>Risultati</b>	<b>21</b>
<b>6</b>	<b>Conclusioni</b>	<b>22</b>

# Todo list

indicare SVM e GNB solo nei risultati? . . . . .	5
famiglie malware . . . . .	6
mostrare tabella esempio diversi DGA . . . . .	6
descrivere distribuzione caratteri Alexa vs dga . . . . .	6
ampliare questa sezione e chiedere a Marchetti . . . . .	7
indicare il capitolo coi risultati di Random Forest . . . . .	7
mostrare esempio supobox . . . . .	8
???????????????????? . . . . .	8
aggiungere ed estendere la teoria MLP nel capitolo precedente? . . . . .	9
inserire grafo ReLU . . . . .	9
inserire grafo sigmoid . . . . .	9
come ampliare???????????????? . . . . .	11
inserire tabella di esempio. . . . .	13
ottenere i parametri di randomforest del miglior risultato . . . . .	19
differenze pratiche tra RF, SVM, GNB . . . . .	19

# Capitolo 1

## Introduzione

In questo capitolo si propongono degli esempi per gli oggetti utilizzati più di frequente in latex: la Sezione 1.1 descrive come scrivere citazioni, la Sezione 1.2 propone degli esempi di oggetti float, la Sezione 1.3 descrive come compilare questo documento.

### 1.1 Citazioni

Inserisco qualche citazione per mostrare la bibliografia. Per gli articoli accademici è quasi sempre possibile reperire i blocchi da inserire nel file bib da scholar, come ad esempio. Scholar in questo caso è una risorsa/sito online e per questo. Precediamo le citazione da uno spazio indivisibile tramite il carattere ~.

### 1.2 Oggetti float

Nella Sezione 1.2.1 si propone un esempio di figura float, mentre nella Sezione 1.2.2 si propone un esempio di tabella float.

#### 1.2.1 Figure

La Figura 1.1 è un esempio di figura float.

# EXAMPLE

**Figura 1.1:** Esempio di figura float in latex.

## 1.2.2 Tabelle

La Tabella 1.1 è un esempio di tabella.

allineamento centrale	allineamento a sinistra	allineamento a destra
centrale	sinistra	destra

**Tabella 1.1:** Esempio di tabella float in latex.

## 1.3 Compilazione

Di seguito il codice da utilizzare per generare il pdf:

```
1 $ pdflatex main.tex
2 $ bibtex main.aux
3 $ pdflatex main.tex
4 $ pdflatex main.tex
```

# **Capitolo 2**

## **Stato dell'arte**

In questo capitolo si propongono degli esempi per gli oggetti utilizzati più di frequente in latex: la Sezione 1.1 descrive come scrivere citazioni, la Sezione 1.2 propone degli esempi di oggetti float, la Sezione 1.3 descrive come compilare questo documento.

# Capitolo 3

## Progetto

In questo capitolo si propone il progetto realizzato per raggiungere gli obiettivi preposti: si è partiti dalla realizzazione di un classificatore basato su *Random Forest* per poi passare ad una versione più elaborata, utilizzando un *Multilayer Perceptron*. Il passo successivo ha riguardato la creazione di una *Generative Adversarial Network* a partire da un *Autoencoder* in grado di rafforzare un classificatore generando domini sintetici

### 3.1 Classificatore Random Forest

La prima fase di questo studio è stata quella di implementare un classificatore in grado di separare efficacemente domini *DGA* da domini non malevoli basandosi unicamente sulle caratteristiche linguistiche dei domini: infatti, ad un esame preliminare, i domini *DGA* presentano caratteristiche ben differenti da semplici frasi o parole che solitamente compongono i domini reali.

Si è scelto di utilizzare Random Forest in quanto ritenuto il più adatto al caso in esame. L'algoritmo è stato inoltre messo a confronto con *Support Vector Machine* e *Naive-Bayes*.

All'interno del classificatore *Random Forest* [?], ogni albero dell'insieme è costruito a partire da un campione estratto con sostituzione dal *training set*. In aggiunta, al momento della divisione del nodo durante la costruzione di un albero, la divisione scelta non è più la migliore soluzione tra tutte le *features*. Al suo posto, la divisione che viene scelta è la migliore divisione all'interno di un *subset* casuale tra tutte le *features*. Come risultato di

indicare  
SVM  
e  
GNB  
solo  
nei  
risul-  
tati?



questa casualità, il *bias* della foresta di solito aumenta leggermente (rispetto al *bias* di un singolo albero non casuale) ma, a causa della media, la sua varianza diminuisce, di solito compensando l'aumento di *bias*, quindi dando un modello generale migliore.

### 3.1.1 Dataset

I *dataset* di *training* e *testing* sono stati ricavati due fonti differenti: per quel che riguarda i domini reali si è fatto riferimento alla classifica dei domini più visitati al mondo fornita da *Alexa Internet Inc.* [1], per un totale di 1 milione di siti realmente esistenti; mentre grazie al repository fornito da [2] è stato possibile ottenere un *dataset* esaustivo di esempi *DGA* da diverse famiglie di *malware*. In particolare le famiglie di malware utilizzate per il training sono state:

A partire da tale *dataset* combinato si è proceduto alla creazione di un classificatore binario che fosse in grado di distinguere domini reali da domini generati alitmicamente.

Il passo seguente stato creare una serie di *features* che fossero in grado di descrivere le caratteristiche linguistiche dei domini presi in esame.

Per raggiungere tale obiettivo si è fatto riferimento a ricerche già esistenti: [3] [4] [5] [6]. Di seguito viene illustrato l'insieme di tali *features*:

### 3.1.2 Features

- **Rapporto tra caratteri significativi.** Modella il rapporto dei caratteri della stringa  $p$  che formano una parola significativa all'interno del dizionario Inglese. Un valore basso indica la presenza di algoritmi automatici. In dettaglio, si divide  $p$  in  $n$  sottoparole significative  $w_i$  di almeno 3 caratteri:  $|w_i| \geq 3$  cercando di lasciare fuori meno caratteri possibili:

$$R(d) = R(p) = \frac{\max(\sum_{i=1}^n |w_i|)}{|p|}$$

Se  $p = \text{facebook}$ ,  $R(p) = \frac{(|\text{face}| + |\text{book}|)}{8} = 1$  allora il dominio è composto completamente da parole significative, mentre  $p = \text{pub03str}$ ,  $R(p) = \frac{|\text{pub}|}{8} = 0.375$ .

famiglie  
mal-  
ware

mostrare  
ta-  
bella  
esem-  
pio

di-  
versi  
DGA

descrivere  
di-  
stri-  
bu-  
zione  
carat-  
teri  
Ale-  
xa vs  
dga

- **Punteggio di normalità degli n-grammi:** Questa classe di *features* modella la pronunciabilità di un nome di dominio rispetto la lingua Inglese. Più la combinazione di fonemi del dominio è presente all'interno del Dizionario Inglese più tale dominio è pronunciabile. Domini con un basso numero di tali combinazioni sono probabilmente generati alitmicamente. Il calcolo avviene estraendo lo n-gramma di  $p$  di lunghezza  $n \in \{1, 2, 3, 4, 5\}$  e contando il numero di occorrenze di tale n-gramma all'interno del Dizionario Inglese. Tali *features* sono quindi parametriche rispetto ad  $n$ :

$$S_n(d) = S_n(p) = \frac{\sum_{\text{n-gramma } t \text{ in } p} \text{count}(t)}{|p| - n + 1}$$

dove  $\text{count}(t)$  sono le occorrenze dello n-gramma nel dizionario. Ad esempio  $S_2(\text{facebook}) = fa_{109} + ac_{343} + ce_{438} + eb_{29} + bo_{118} + oo_{114} + ok_{45} = 170.8$

- **Rapporto tra caratteri numerici** Questa *feature* rappresenta il rapporto tra i caratteri numerici presenti all'interno del nome di dominio rispetto la lunghezza totale della parola. Molte famiglie di *malware* utilizzano *DGA* che generano domini tramite una distribuzione uniforme di caratteri alfabetici minuscoli e numeri, questo porta a domini generati alitmicamente che presentano una maggior presenza di numeri al loro interno rispetto ai domini reali.
- **Rapporto tra vocali e consonanti** Questa *feature* modella il rapporto tra vocali e consonanti all'interno del nome di dominio.
- **Lunghezza del nome di dominio** Questa *feature* calcola la lunghezza del dominio. Molte famiglie di *malware* utilizzano *DGA* che generano domini di lunghezza costante, generalmente molto lunghi rispetto ai domini reali.

L'implementazione di tali *features* ha permesso di ottenere un *dataset* in grado di modellare le caratteristiche linguistiche dei nomi di dominio mostrati al capitolo 3.1.1. Da tale punto è partita la fase iniziale di *testing*

### 3.1.3 Output

L'obiettivo di tale classificatore è quello di riuscire a separare in maniera efficace i domini reali da quelli generati alitmicamente. A tale proposito ???

Durante la fase di sperimentazione il classificatore si è rivelato efficace rispetto la maggior parte delle famiglie di *DGA*. Il caso particolare della famiglia *suppobox* [7] ha messo in particolare difficoltà il classificatore in quanto tale algoritmo genera domini in maniera pseudo-casuale, concatenando due parole a partire da un *subset* del dizionario inglese di 384 parole. Tale caratteristica fa sì che le *features* linguistiche estratte da questa famiglia di *malware* siano molto simili a quelle presenti nei domini reali.

A partire da questo risultato si scelto di procedere con la progettazione di un classificatore neurale in grado di superare tale problematica.

## 3.2 Classificatore Neurale

Questo classificatore neurale nasce con l'intento di superare le difficoltà incontrate dal precedente classificatore basato su *Random Forest*, utilizzando le caratteristiche delle reti neurali, in grado di estrarre *features* a partire dai dati grezzi. Si è scelto di partire dall'architettura di tipo *Multilayer Perceptron* con l'obiettivo di ottenere risultati migliori rispetto al caso mostrato nella sezione precedente.

I passi del progetto sono stati la codificazione dei domini in valori numerici, l'individuazione di una architettura ottimale per classificare i dati in esame ed un'ultima fase di *tuning* degli iperparametri della rete neurale.

### 3.2.1 Input

A partire dal *dataset* creato per il precedente caso, si è deciso di convertire direttamente i nomi di dominio alfanumerici in vettori numerici, mappati secondo il dizionario di tutti i caratteri ammessi [8] (lettere minuscole a-z, numeri 0-9, tratto d'unione "-"). L'obiettivo è quello di fornire al classificatore neurale in questione una rappresentazione il più possibile aderente ai dati reali, senza l'ausilio di *features* ingegnerizzate a priori, lasciando così la libertà alla rete neurale di estrarre le caratteristiche più appropriate per la distinzione dei domini. Come scelta progettuale si è deciso di limitare la dimensione dei domini a 15 caratteri

mostrare

esem-  
pio  
sup-  
po-  
box

??????

per ognuno, in modo da ottenere un *dataset* di dimensioni fissate e sopperire alle differenti lunghezze di ogni dominio tramite un semplice *padding* di zeri in testa ad ogni stringa codificata.

Assieme ai dati codificati è stato generato un vettore di *target* nel quale viene indicato da 0 o da 1 se il dominio in esame è di tipo reale o generato alitmicamente. L'obiettivo quindi è di attuare un classificatore binario in grado di prevedere correttamente a quale categoria appartiene un dominio esaminato

### 3.2.2 Architettura

L'architettura scelta in prima fase è stata quella del *Multilayer Perceptron* (abbr. *MLP*), una tipologia di rete neurale *feedforward* tipicamente formata da almeno tre livelli di nodi. Ad esclusione del livello di *input* i livelli del MLP utilizzano funzioni di attivazione non lineari che permettono di eseguire distinzioni tra dati non linearmente separabili. Considerando una rete formata da  $m$  neuroni, se si considera  $d$  come numero di input, si avrà il seguente output

$$y_j = y \left( \sum_{i=0}^d w_{ji} x_i \right)$$

nel quale  $x_i$  sono gli input e  $w_{ji}$  sono i pesi di ogni input combinati con ogni output.

Nel caso in esame è stata utilizzata per i livelli interni la funzione di attivazione *Rectifier Linear Unit* (ReLU) [9] definita dalla funzione

$$f(x) = x^+ = \max(0, x)$$

dove  $x$  rappresenta l'*input* del neurone. I vantaggi di tale funzione sono una migliorata performance rispetto ad altre funzioni similari come *tanh* e *sigmoid* per quel che riguarda la convergenza della discesa stocastica del gradiente.

Per quel che riguarda la funzione di attivazione del livello di *output* si è scelta la funzione *sigmoidea*, definita dalla formula

$$P(t) = \frac{1}{1 + e^{-t}}$$

aggiungere

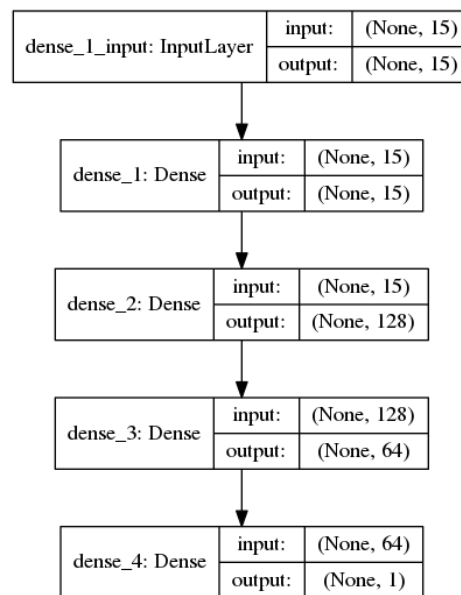
ed  
estendere  
la  
teoria  
MLP  
nel  
capitolo  
precedente?

inserire  
grafo

La struttura finale del *MLP* in esame è stata raggiunta dopo una serie di test sperimentali in cui si sono messi a confronto tre modelli differenti di per numero di neuroni all'interno degli *hidden layer*:

- un modello ridotto composto da un layer di input con un numero di neuroni pari alla dimensione delle stringhe codificate, un layer intermedio di dimensione dimezzata rispetto al precedente ed il layer finale di uscita di dimensione 1 per attuare la classificazione binaria, oggetto di studio.
- un modello allargato composto da un layer di input con un numero di neuroni pari alla dimensione delle stringhe codificate, due layer intermedi di dimensioni moltiplicate di diversi ordini rispetto al layer iniziale ed un layer finale di dimensione 1.
- un modello intermedio composto da un layer di input con un numero di neuroni pari alla dimensione delle stringhe codificate, un layer intermedio di dimensione 128, un layer di dimensione minore a 64 ed un layer finale di dimensione 1. (Figura 3.1)

I tre modelli messi a confronto hanno mostrato risultati simili, tuttavia il modello intermedio si è dimostrato più performante, con un costo computazionale irrisorio rispetto al modello allargato, pertanto è stato scelto come riferimento per gli studi successivi.



**Figura 3.1:** Grafico del modello intermedio. Escluso il layer di input iniziale, si notino gli *hidden layer* dense2 e dense3 di dimensioni rispettivamente 128 e 64

### 3.2.3 Output

L'intento della rete neurale proposta è quello di classificare autonomamente domini reali da domini generati alitmicamente, con l'obiettivo di superare le fragilità del classificatore precedente (3.1) ed avere una linea di confronto affidabile per lo *step* di lavoro successivo: l'introduzione di un sistema di *adversarial learning* che possa rafforzare tale classificatore.

come  
am-  
plia-  
re?????????

### 3.2.4 Realizzazione Adversarial Learning


Ricerche precedenti hanno dimostrato che molti modelli di machine learning, incluse le reti neurali, sono vulnerabili agli *adversarial examples* [10], [11]. In particolare la ricerca proposta in [11] introduce il metodo del *fast gradient sign* per scoprire *adversarial examples* perturbando un campione noto  $x$  con una piccola quantità  $\Delta x = \epsilon \text{sign}(\nabla_x J(\theta, x, y))$  dove  $\theta$  rappresenta i parametri del modello e  $J$  il costo necessario a classificare  $x$  come  $y$ . Separatamente [12] propone l'uso di *Generative Adversarial Network* (abbr. *GAN*) come *framework* in grado di generare campioni artificiali provenienti dalla stessa distribuzione del training set. Le *GAN* incorporano due modelli: un generatore ed un discriminatore i quali competono in una serie di turni antagonisti. All'interno del contesto del lavoro presentato in questo elaborato, il generatore impara a creare nuovi domini artificiali mentre il discriminatore impara a distinguere tali domini artificiali da quelli reali. L'intento di tale lavoro è usare la *GAN* per produrre domini artificiali realistici e di conseguenza incrementare la precisione del classificatore presentato nella sezione precedente attraverso l'*adversarial training*. I presupposti progettuali di questo elaborato sono ispirati alla ricerca presentata in [13].

## 3.3 Autoencoder

Il punto di partenza per il lavoro di progettazione di una *GAN* è stato l'implementazione di un *Autoencoder* funzionante. Un *Autoencoder* è un modello di rete neurale non supervisionata con lo scopo di riprodurre il proprio input passando attraverso una rappresentazione codificata, generalmente a dimensione inferiore [14] [15]. Si supponga di avere un set di training  $\{x^{(1)}, x^{(2)}, x^{(3)}, \dots\}$  dove  $x^{(i)} \in \mathbb{R}^n$ . L'obiettivo di un autoencoder generico è  $y^{(i)} = x^{(i)}$  cer-

cando di imparare una funzione che approssima  $x$   $h_{W,b}(x) \approx x$ . Un *autoencoder* tipicamente consiste in due macro-componenti:

- funzione **Encoder**  $h = f(x)$  la quale trasforma l'input in una rappresentazione codificata (generalmente a dimensione minore)
- funzione **Decoder**  $r = g(h)$  in grado di ricostruire l'input a partire dalla rappresentazione codificata.



**Figura 3.2:** Struttura generica di un autoencoder, il quale mappa l'input  $x$  in un output  $r$  attraverso una rappresentazione codificata  $h$

Tuttavia il reale obiettivo di un *autoencoder* non è quello di imparare perfettamente a riprodurre l'input fornito (in quanto sarebbe un'operazione priva di utilità), bensì vengono introdotti vincoli che ne limitano la capacità di riproduzione ad una sola approssimazione dei dati di ingresso. Grazie a tali vincoli il modello è obbligato a dare priorità agli aspetti fondamentali dell'input, imparandone le proprietà principali. L'obiettivo di tale implementazione nel contesto di questo elaborato è poter cogliere le caratteristiche fondamentali che compongono i domini reali, per poterli riprodurre al meglio all'interno della GAN e generare domini simili a quelli reali a partire da rumore casuale.

### 3.3.1 Dataset Autoencoder

Il *dataset* utilizzato per il training di tale *autoencoder* è lo stesso mostrato nella sezione 3.2.1, in cui i domini sono mappati in vettori numerici, secondo il dizionario di caratteri ammissi-

bili per i domini. Durante la fase di implementazione si è reso necessario un ulteriore *step* di *preprocessing*: i domini codificati in sequenze di valori interi sono stati ulteriormente codificati tramite il *one hot encoding* [16] in modo da formare un tensore 2D per ogni dominio, in cui ogni riga è formata da sequenze di bit a 0 tranne il carattere nella posizione indicata dal dizionario, il quale è indicato ad 1. I domini così codificati vengono trattati come una sequenza temporale, in cui ogni *step* è caratterizzato da un vettore nel quale è indicato a 1 quale carattere del dizionario  $\mathbb{V}$  vi è rappresentato.

Questo ulteriore passaggio è diventato necessario durante l'implementazione della GAN, in modo da poter utilizzare il tensore di output del *decoder* come ingresso per l'*encoder*.

inserire  
tabel-  
la di  
esem-  
pio.

### 3.3.2 Architettura Autoencoder

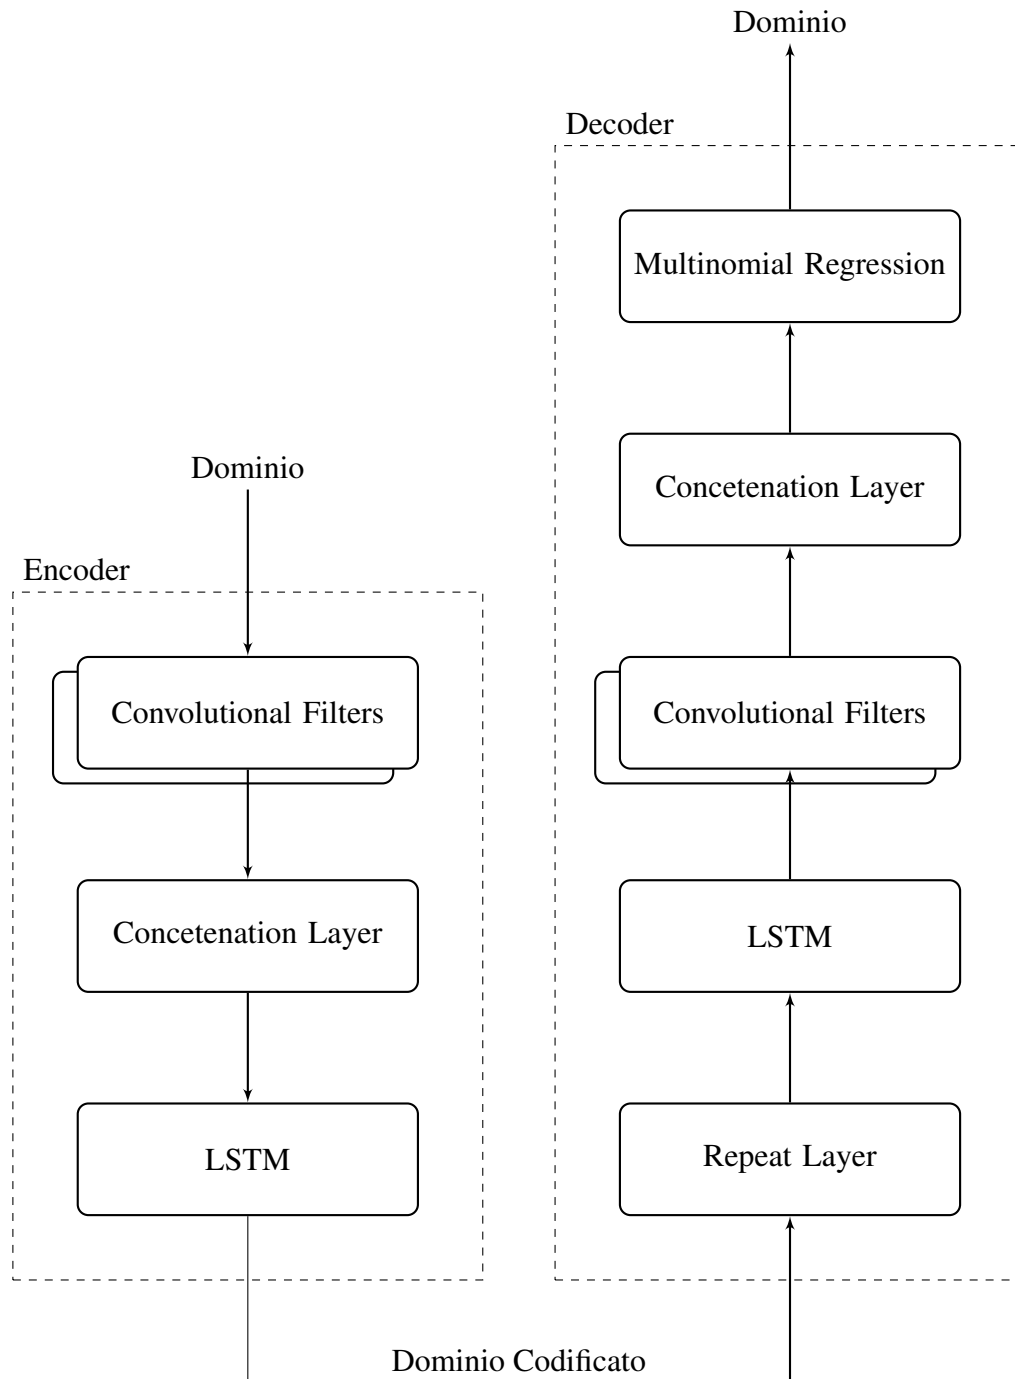
L'architettura dell'*encoder* in esame è ispirato al lavoro mostrato in [17] mentre il *decoder* è approssimativamente una immagine speculare dell'*encoder*.

Al domini codificati come indicato nella sezione precedente, vengono applicati dei filtri convoluzionali con l'obiettivo di catturare n-grammi significativi all'interno dei domini reali. Il layer successivo di concatenazione assembla l'output dei diversi filtri in un tensore di dimensione ridotta rispetto all'input iniziale e lo passa ad una LSTM la quale accumula stato lungo la sequenza di caratteri e ritorna in uscita il dominio codificato in forma di vettore mono-dimensionale.

Il *decoder* è l'opposto del processo di codifica: il dominio codificato dato in input viene ripetuto un numero di volte equivalente alla lunghezza massima di nome di dominio decisa a priori e passato ad una LSTM. La sequenza di emissioni da parte del layer LSTM viene fornita agli stessi filtri convoluzionali presenti all'interno dell'*encoder*. Questo risulta in un vettore  $\mathbb{V}$ -dimensionale per ogni elemento della sequenza che compone il dominio. Lo step finale consiste di un dense layer con distribuzione temporale che agisce come regressore multinomiale. A causa dell'attivazione *softmax* attuata sul *dense layer*, l'output del decoder rappresenta una distribuzione multinomiale dei caratteri di  $\mathbb{V}$  per ogni step temporale, la quale può essere campionata per produrre un nuovo nome di dominio contenente le caratteristiche principali dei nomi di dominio usati in input.



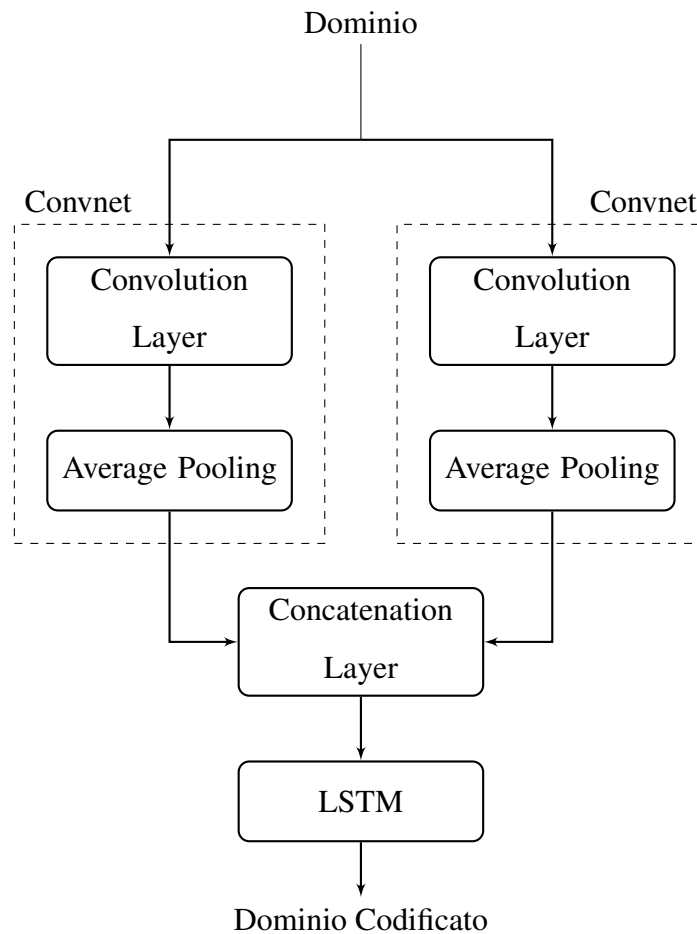
In figura 3.3 è mostrata la struttura di massima dell'autoencoder. Di seguito vengono illustrati in dettaglio le principali componenti che compongono l'*autoencoder*.



**Figura 3.3:** Struttura dell'*autoencoder* in esame. L'input in ingresso dato dai domini viene codificato attraverso l'*encoder* e dato in ingresso al *decoder* che ne genera una approssimazione

### 3.3.2.1 Encoder

La composizione interna dell'*encoder* è formata da una Rete Convoluzionale accoppiata ad una LSTM. A differenza del lavoro proposto in [13], si è voluto mantenere la composizione dell'autoencoder il più semplice possibile, in quanto la trasformazione in *GAN* ed il suo *tuning* in fase di *training* è notoriamente difficoltoso in presenza di molti parametri. In Figura 3.4 viene mostrata la struttura semplificata dell'encoder.



**Figura 3.4:** Struttura dell'*encoder*

Una Rete Convoluzionale è un modello di rete neurale usato generalmente per classificazione di immagini, in alternativa ai layer densamente connessi. Il vantaggio nell'uso delle reti convoluzionali è la capacità di quest'ultime di memorizzare pattern locali all'interno dello spazio di input mentre layer densamente connessi sono in grado di riconoscere solo pattern globali. Nel caso in esame si sono applicati due filtri convoluzionali in parallelo, con l'obiettivo di cogliere pattern locali all'interno dei domini, ovvero n-grammi significativi da poter

replicare. Generalmente i filtri convoluzionali lavorano su di un tensore 3-dimensionale, chiamato *feature map*, avente due assi spaziali ("altezza" e "larghezza") ed un asse di profondità; nel caso di riconoscimento di immagini tali assi corrispondono alle dimensioni dell'immagine di input ed al numero dei canali colore. Nel caso in esame si sono trattati di input tridimensionali ad altezza 1, larghezza equivalente alla dimensione massima dei domini nel dataset e canale di dimensione 1. L'operazione di convoluzione estrae frammenti dalla *feature map* di input ed applica una trasformazione a tutti i frammenti, generando una *output feature map* la quale è ancora in forma di tensore 3D, di dimensione ridotta, contenente sull'asse della profondità i valori dei *filtri*. I filtri codificano determinati aspetti caratteristici dell'input, analizzando l'input in una "finestra" di dimensione fissata che scorre lungo la sequenza; ad ogni passo il filtro estrae il sotto-tensore 3-dimensionale per trasformarlo (tramite un prodotto tensore con una matrice di pesi (chiamato *convolutional kernel*) in un vettore 1D di dimensione fissata. L'insieme di vettori vengono riassemblati in un tensore 3D con altezza e larghezza identiche alle precedenti e l'insieme di features come terzo asse.

Parte integrante di una rete convoluzionale è il livello di *pooling*, in cui le features più importanti del livello precedente vengono ridotte in un tensore di dimensione inferiore, secondo il valor medio all'interno della *feature map*. La decisione di utilizzare average pooling anziché max pooling è stata presa a causa dell'elevata instabilità intrinseca alle GAN, per le quali max pooling è un fattore contribuyente.

Il layer aggiuntivo di *concatenazione* funge per mettere di formare un unico vettore monodimensionale in grado di fornire le caratteristiche principali dei domini analizzati.

Seconda fase della sottorete Encoder è la presenza di una Long Short-term Memory Network (abbr *LSTM*) [18]. Si tratta di un modello di *Recurrent Neural Network* (abbr. *RNN*) particolare, in grado di apprendere dipendenze a lungo termine all'interno di una sequenza temporale che nasce con l'intento di superare le principali problematiche delle RNN semplici, le quali non sono in grado di gestire dipendenze a lungo termine all'interno di una sequenza temporale. Le celle LSTM consistono di uno stato che può essere letto, scritto e resettato attraverso una serie di *gates*. Siano dati  $W$  e  $U$  layer di una cella LSTM corrispondenti a matrici di pesi per l'input  $x$  ed emissione  $h$ , mentre  $b$  vettore di bias. Lo stato  $c$  di una cella LSTM ha connessioni periodiche che permettono ad ogni cella di mantenere stato

attraverso gli step temporali:

$$c_t = f \cdot c_{t-1} + i_t \cdot g_t$$

dove  $\cdot$  denota moltiplicazione tra elementi. Gli stati possono essere aggiornati in maniera additiva tramite

$$g_t = \tanh(W^g x_t + U^g h_{t-1} + b^g)$$

attraverso i gate di input  $i$ , in grado di moltiplicare l'aggiornamento di stato di un numero che varia da 0 ad 1. Alla stessa maniera il *forget gate*  $f$  modula la connessione *self-recurrent* tra ogni cella di un numero compreso tra 0 ed 1. In tal maniera è possibile ignorare l'input e mantenere lo stato, oppure sovrascrivere lo stato corrente o resettarlo a 0. L'output gate  $o$  modula il contributo fornito dallo stato di ogni cella come

$$h_t = o_t \cdot \tanh(c_t),$$


il quale è propagato agli input gate dei livelli successivi. In particolare i gate di input, forget e output sono definite da una funzione dell'input  $x_t$  e dall'emissione del layer LSTM precedente  $h_t$  all'istante  $t$  come:

$$i_t = \sigma(W^i x_t + U^i h_{t-1} + b^i)$$

$$f_t = \sigma(W^f x_t + U^f h_{t-1} + b^f)$$

$$o_t = \sigma(W^o x_t + U^o h_{t-1} + b^o).$$

Il design delle celle LSTM con gate moltiplicativi permette ad una rete neurale di immagazzinare ed accedere allo stato attraverso lunghe sequenze, mitigando le problematiche presenti all'interno delle *RNN* semplici. Nel contesto di questo progetto, lo spazio degli stati è inteso a catturare le combinazioni di tokens (n-grammi) che sono importanti per modellare nomi di dominio realistici. In figura 3.5 è indicata la struttura di una cella LSTM.



**Figura 3.5:** Struttura di una cella LSTM

### **3.3.2.2 Decoder**

descrizione

repeat layer why LSTM

Convnet why

multinomial regrassion + table

## **3.4 Generative Adversarial Network**

### **3.4.1 Output**

# Capitolo 4

## Implementazione

### 4.1 Classificatore Random Forest

ottenere  
i  
para-  
metri  
di  
ran-  
dom-  
forest  
del  
mi-  
glior  
risul-  
tato

differenze  
pra-  
tiche  
tra  
RF,  
SVM,  
GNB

### **4.1.1 Input**

### **4.1.2 Composizione Interna**

### **4.1.3 Output**

## **4.2 Classificatore Neurale**

### **4.2.1 Input**

### **4.2.2 Composizione Interna**

### **4.2.3 Output**

## **4.3 Realizzazione Adversarial Learning**

### **4.3.1 Input**

### **4.3.2 Composizione Interna**

### **4.3.3 Output**

# Capitolo 5

## Risultati

In questo capitolo si propongono degli esempi per gli oggetti utilizzati più di frequente in latex: la Sezione 1.1 descrive come scrivere citazioni, la Sezione 1.2 propone degli esempi di oggetti float, la Sezione 1.3 descrive come compilare questo documento.



# Capitolo 6

## Conclusioni

In questo capitolo si propongono degli esempi per gli oggetti utilizzati più di frequente in latex: la Sezione 1.1 descrive come scrivere citazioni, la Sezione 1.2 propone degli esempi di oggetti float, la Sezione 1.3 descrive come compilare questo documento.

# Bibliografia

- [1] Amazon, “Alexa.” <https://www.alexa.com/>, visited in Sep. 2017.
- [2] A. Abakumov, “Dga.” <https://github.com/andrewaeva/DGA>, visited in Sep. 2017.
- [3] M. Antonakakis, R. Perdisci, Y. Nadji, N. Vasiloglou, S. Abu-Nimeh, W. Lee, and D. Dagon, “From throw-away traffic to bots: Detecting the rise of dga-based malware,” in *Presented as part of the 21st USENIX Security Symposium (USENIX Security 12)*, (Bellevue, WA), pp. 491–506, USENIX, 2012.
- [4] S. Yadav, A. K. K. Reddy, A. N. Reddy, and S. Ranjan, “Detecting algorithmically generated malicious domain names,” in *Proceedings of the 10th ACM SIGCOMM Conference on Internet Measurement, IMC '10*, (New York, NY, USA), pp. 48–61, ACM, 2010.
- [5] S. Yadav, A. K. K. Reddy, A. L. N. Reddy, and S. Ranjan, “Detecting algorithmically generated domain-flux attacks with dns traffic analysis,” *IEEE/ACM Trans. Netw.*, vol. 20, pp. 1663–1677, Oct. 2012.
- [6] S. Schiavoni, F. Maggi, L. Cavallaro, and S. Zanero, *Phoenix: DGA-Based Botnet Tracking and Intelligence*, pp. 192–211. Cham: Springer International Publishing, 2014.
- [7] J. Geffner, “End-to-end analysis of a domain generating algorithm malware family,” *Black Hat USA*, vol. 2013, 2013.
- [8] ICANN. <https://www.icann.org/>.

- [9] X. Glorot, A. Bordes, and Y. Bengio, “Deep sparse rectifier neural networks,” in *Proceedings of the Fourteenth International Conference on Artificial Intelligence and Statistics* (G. Gordon, D. Dunson, and M. Dudík, eds.), vol. 15 of *Proceedings of Machine Learning Research*, (Fort Lauderdale, FL, USA), pp. 315–323, PMLR, 11–13 Apr 2011.
- [10] C. Szegedy, W. Zaremba, I. Sutskever, J. Bruna, D. Erhan, I. Goodfellow, and R. Fergus, “Intriguing properties of neural networks,” 2013.
- [11] I. J. Goodfellow, J. Shlens, and C. Szegedy, “Explaining and harnessing adversarial examples,” 2014.
- [12] I. J. Goodfellow, J. Pouget-Abadie, M. Mirza, B. Xu, D. Warde-Farley, S. Ozair, A. Courville, and Y. Bengio, “Generative adversarial networks,” 2014.
- [13] H. S. Anderson, J. Woodbridge, and B. Filar, “Deepdga: Adversarially-tuned domain generation and detection,” 2016.
- [14] Y. Bengio, “Learning deep architectures for ai,” *Foundations and Trends® in Machine Learning*, vol. 2, no. 1, pp. 1–127, 2009.
- [15] C.-Y. Liou, J.-C. Huang, and W.-C. Yang, “Modeling word perception using the elman network,” *Neurocomput.*, vol. 71, pp. 3150–3157, Oct. 2008.
- [16] D. Harris and S. Harris, *Digital Design and Computer Architecture, Second Edition*, p. 129. Morgan Kaufmann, 2012.
- [17] Y. Kim, Y. Jernite, D. Sontag, and A. M. Rush, “Character-aware neural language models,” 2015.
- [18] S. Hochreiter and J. Schmidhuber, “Long short-term memory,” vol. 9, pp. 1735–80, 12 1997.